基于可学习通道重排的 MXFP4 量化优化

组会汇报

2026 年 4 月 14 日

1. 问题背景

考虑 MoE 中某个 expert 的 `down_proj`：

$$x \in \mathbb{R}^{B\times D}, \qquad w \in \mathbb{R}^{O\times D}, \qquad y_{\text{ref}} = xw^{\top} \in \mathbb{R}^{B\times O}$$

在不做通道重排时，直接量化得到

$$y_q^{(\text{id})} = Q(x)\,Q(w)^{\top}$$

其重建误差通常受输入通道排列方式影响较大，特别是在分组量化场景下：

$$\mathcal{L}_{\text{id}} = \text{MSE}\left(y_q^{(\text{id})},\, y_{\text{ref}}\right)$$

本工作的核心问题是：

目标

是否能仅通过学习一个输入通道 permutation，在不改权重数值的前提下，降低 MXFP4 量化误差？

2. 核心思路

我们为每个 expert 学习一个 permutation $P \in \{0,1\}^{D\times D}$，满足

$$P\mathbf{1} = \mathbf{1}, \qquad P^\top \mathbf{1} = \mathbf{1}$$

重排后的激活与权重为

$$x' = xP^\top, \qquad w' = wP^\top$$

量化输出写作

$$y_q(P) = Q(xP^\top)\, Q(wP^\top)^\top$$

因而目标变为

$$\min_{P\in\Pi_D} \mathcal{L}_{\text{recon}}(P) = \min_{P\in\Pi_D} \text{MSE}(y_q(P),\, y_{\text{ref}})$$

其中 Π_D 表示所有 D 维 permutation matrix 的集合。

3. 参数化：从离散 permutation 到连续 score

直接优化离散 permutation 很困难，因此引入一维可学习参数

$$s = (s_1, \ldots, s_D) \in \mathbb{R}^D$$

先做标准化：

$$\tilde{s} = \frac{s - \mathrm{mean}(s)}{\mathrm{std}(s) + \varepsilon}$$

再由 score 诱导排序。离散路径上，

$$\pi_{\mathrm{hard}} = \mathrm{argsort}(\tilde{s})$$

并进一步构造 hard permutation matrix

$$P_{\mathrm{hard}}[r, \pi_{\mathrm{hard}}(r)] = 1$$

这样，每个 expert 的训练参数仅为长度 D 的 score 向量，参数量非常小。

4. Soft permutation 的构造

对标准化后的 score，先排序得到

$$\tilde{s}_{(1)} \leq \tilde{s}_{(2)} \leq \cdots \leq \tilde{s}_{(D)}$$

构造 cost matrix：

$$C_{r,i} = \begin{cases} |\tilde{s}_{(r)} - \tilde{s}_i|, & \text{L1 metric} \\ (\tilde{s}_{(r)} - \tilde{s}_i)^2, & \text{L2 metric} \end{cases}$$

再定义

$$\log \alpha = -\frac{C}{\tau}$$

通过 Sinkhorn 归一化得到 soft permutation：

$$P_{\text{soft}} = \text{Sinkhorn}(\exp(\log \alpha))$$

其中温度 τ 控制软硬程度：

$$\tau \downarrow \quad \Longrightarrow \quad P_{\text{soft}} \text{ 更接近 one-hot/permutation}$$

5. Permutation 的 STE

训练时同时维护：

$$P_{\text{hard}}, \qquad P_{\text{soft}}$$

用 straight-through estimator 将二者结合：

$$P_{\text{ste}} = P_{\text{hard}} - \text{sg}(P_{\text{soft}}) + P_{\text{soft}}$$

其性质是：

$$\text{forward: } P_{\text{ste}} \equiv P_{\text{hard}}, \qquad \text{backward: } \frac{\partial P_{\text{ste}}}{\partial s} = \frac{\partial P_{\text{soft}}}{\partial s}$$

解释

前向时，我们尽量按照真实离散 permutation 来训练；反向时，梯度仍然通过 soft relaxation 传播。

6. MXFP4 Fake Quant 与量化 STE

对重排后的张量按最后一维分组，group size 记为 g。对每个分组：

$$a_{\max} = \max |x|$$

主 scale 取为

$$s_{\text{blk}} = 2^{\lfloor \log_2 \left(\frac{8}{7} a_{\max} \right) \rfloor}$$

再对归一化值计算 secondary scale，并执行离散化。最终得到 fake quant 值 $Q(x)$。

为了让量化可训练，使用

$$Q_h(x) = x + \text{sg}(Q(x) - x)$$

因而：

$$\text{forward 用 } Q(x), \qquad \text{backward 近似看作 identity}$$

这意味着当前方案中同时存在两层 STE：

$$s \to P_{\text{ste}} \to Q_h(\cdot)$$

7. 损失函数

参考输出定义为

$$y_{\text{ref}} = xw^\top$$

训练时前向路径为

$$x_{\text{perm}} = xP_{\text{ste}}^\top, \qquad w_{\text{perm}} = wP_{\text{ste}}^\top$$

$$y_q = Q_h(x_{\text{perm}})\, Q_h(w_{\text{perm}})^\top$$

当前实际优化目标：

$$\mathcal{L} = \underbrace{\text{MSE}(y_q, y_{\text{ref}})}_{\mathcal{L}_{\text{recon}}} + \lambda_{\text{ds}} \underbrace{\left(\|P_{\text{soft}}\mathbf{1} - \mathbf{1}\|_2^2 + \|P_{\text{soft}}^\top\mathbf{1} - \mathbf{1}\|_2^2 \right)}_{\mathcal{L}_{\text{ds}}}$$

当前版本只保留了真正使用的双随机正则项。

8. 训练与评估口径

训练口径

$$\mathcal{L}_{\text{train}} = \mathcal{L}\big(P_{\text{ste}}\big)$$

评估口径

$$\mathcal{L}_{\text{hard}} = \text{MSE}\Big(Q_h(xP_{\text{hard}}^\top)\, Q_h(wP_{\text{hard}}^\top)^\top,\ y_{\text{ref}}\Big)$$

baseline 则取 identity permutation：

$$P = I \quad \Longrightarrow \quad \mathcal{L}_{\text{base}} = \mathcal{L}_{\text{hard}}(I)$$

相对收益定义为

$$\text{Improve} = \frac{\mathcal{L}_{\text{base}} - \mathcal{L}_{\text{final}}}{\max(|\mathcal{L}_{\text{base}}|, \epsilon)}$$

训练中真正关心的不是单调下降，而是最终 hard 口径是否优于 baseline。

9. 温度退火与 Early Stop

温度采用指数退火：

$$\tau_t = \tau_{\text{start}} \left(\frac{\tau_{\text{end}}}{\tau_{\text{start}}} \right)^{\frac{t}{T-1}}$$

为降低离散训练的高频波动，对 hard eval loss 做 EMA：

$$m_t = \begin{cases} \ell_t, & t = 0 \\ \beta m_{t-1} + (1-\beta)\ell_t, & t \geq 1 \end{cases}$$

其中 $\ell_t = \mathcal{L}_{\text{hard}}^{(t)}$。

若连续若干轮没有达到相对改善阈值，则 early stop。

作用

这一步主要是稳住停止条件，而不是保证训练曲线单调。

10. 局部离散 Refinement

训练结束后，从当前最优 permutation 出发，做少量 pair-swap hill climbing：

$$\pi \to \pi'$$

其中 π' 由交换 π 中两个位置得到。
对每个候选 permutation，重新计算

$$\mathcal{L}_{\text{hard}}(\pi')$$

若

$$\mathcal{L}_{\text{hard}}(\pi') < \mathcal{L}_{\text{hard}}(\pi)$$

则接受更新。

这一步的意义是：

- 训练阶段优化的是可导近似目标
- refinement 直接在真实 hard 目标上做局部离散搜索
- 常能额外捡到一部分 hard loss 收益

11. 多卡并行策略

当前实现采用 expert 级并行，而非梯度同步并行。
对于总 expert 数 E、进程数 W、当前 rank r：

$$\mathcal{E}_r = \{\, r,\ r+W,\ r+2W,\ \dots \}$$

每个进程只处理集合 $\mathcal{E}_r$ 中的 expert。

设备分配：

$$\text{device} = \texttt{npu:LOCAL_RANK}$$

这种方式的特点：

- expert 间相互独立，天然适合任务并行
- 实现比 DDP 更简单
- 无需在 rank 间同步 score 参数

12. 结果产物设计

每个 expert 会保存一份结果对象，包含：

$$\{\text{config},\ \text{baseline},\ \text{best_perm},\ \text{best_score},\ \text{loss history},\ \ldots\}$$

关键字段包括：

- $\mathcal{L}_{\text{base}}$
- $\mathcal{L}_{\text{best_before_refine}}$
- $\mathcal{L}_{\text{refined}}$
- $\mathcal{L}_{\text{final}}$
- best permutation / best score
- loss / EMA / tau / lr 的历史序列

同时提供后处理脚本，为每个 expert 绘制：

- hard eval loss 曲线
- baseline 水平线
- refine 前后最优值对比

13. 当前现象与理解

当前实验已经实现：

- 方法链路打通
- 多卡运行
- 结果保存与自动画图

但目前观察到：

$$\mathcal{L}_{\text{hard}}^{(t)}$$

在不少 expert 上存在较强波动，整体下降趋势也不总是明显。

这与以下因素有关：

- permutation 本身是离散对象
- 训练中同时用了 permutation STE 和 quant STE
- soft 训练目标与 hard 评估目标之间存在 gap
- 学习率、温度退火等超参可能仍需继续调

14. 下一步工作

后续重点并不在工程链路，而在训练稳定性与收益验证：

调参与训练稳定性

调整学习率、温度终值、退火速度，观察 hard eval 口径是否更稳定优于 baseline。

统计性验证

统计更多层、更多 expert 上的收益分布，而不是只看单个曲线。

目标对齐

进一步分析 soft 训练路径与 hard 最终目标之间的差距，以及 refine 的贡献占比。

总结

1. 当前方案本质上是在 expert 级别学习量化友好的输入通道重排
2. 方法上结合了 softsort、Sinkhorn、permutation STE 与 quant STE
3. 工程上已经支持多卡并行、结果保存与自动可视化
4. 当前主要瓶颈是训练稳定性与最终收益强度，而不是实现完整性

谢谢